

FGV EMap
João Pedro Jerônimo

Ciência de Redes
Revisão para A1

Rio de Janeiro
2025

Conteúdo

1	Grafos	3
2	Medidas de Centralidade	6
3	Redes Aleatórias	13
3.1	Ideia Inicial	14
3.2	Evolução das Redes Aleatórias	15
3.2.1	Regime Subcrítico ($0 < \hat{k} < 1$)	17
3.2.2	Ponto Crítico	17
3.2.3	Regime Supercrítico ($\hat{k} > 1$)	18
3.2.4	Regime Conexo ($\hat{k} > \ln(N)$)	18
3.3	Distribuição de tamanhos de Cluster	19
3.4	Mundos pequenos	19
3.5	Coeficiente de Clustering	19
3.6	Conclusão	20
4	Evoluções de Redes	21
4.1	Anexação Uniforme	22
4.2	Anexação Preferencial	23

Grafos

De antemão valhe ressaltar que essa matéria, por mais que seja chamada de **Ciência de Redes**, o termo **rede** se refere a um grafo, não ao tipo específico de grafo que se é visto em **Fluxo em Redes** quando estudamos matemática discreta. Então que já fique esclarecido de antemão que, ao citarmos redes, estamos nos referindo a um grafo no geral, desde que o contrário seja explicitado

Essa sessão será apenas algumas definições que não foram passadas no curso de Matemática Discreta, então conceitos que forem citados sobre grafos e não houver definição nesse resumo, a mesma estará no recap de Matemática Discreta. Aqui segue algumas notações sobre grafos para que não fique confuso:

- $G(V, E) :=$ Grafo com conjunto de vértices V e de arestas E (edges)
- $N(v) :=$ Vizinhança do vértice v (Neighbourhood)
- $\delta(v) :=$ Grau do vértice v
- $K_n :=$ Grafo completo com n vértices
- $K_{m,n} :=$ Grafo completo bipartido com m vértices no primeiro conjunto e n vértices no segundo
- $X(G) :=$ Número cromático de G
- $X'(G) :=$ Número cromático por arestas de G

Definição 1.1 (Grau Médio): Dado um grafo não-dirigido $G(V, E)$, o grau médio de G é:

$$\delta_{\text{med}}(G) := \frac{1}{|V|} \sum_{v_i \in V} \delta(v_i) \quad (1)$$

Se G é dirigido, podemos definir os graus médios de entrada e saída

$$\delta_{\text{med}}^{\text{in}}(G) := \frac{1}{|V|} \sum_{v_i \in V} \delta^{\text{in}}(v_i) \quad \text{Entrada} \quad (2)$$

$$\delta_{\text{med}}^{\text{out}}(G) := \frac{1}{|V|} \sum_{v_i \in V} \delta^{\text{out}}(v_i) \quad \text{Saída} \quad (3)$$

Definição 1.2 (Distribuição do Grau): A distribuição do grau de um Grafo $G(V, E)$ é a distribuição da variável aleatória X , sendo X o grau do vértice que eu escolho ao acaso

Para os teoremas a seguir e daqui em diante, consideremos a matriz de incidência de forma que $A_{ij} = 1$ se a aresta j se conecta no vértice i e, 0 do contrário (-1 se G for dirigido).

Teorema 1.1: Dado um grafo $G(V, E)$ e sua matriz de incidência A , temos que:

$$\text{n}^\circ \text{ de ciclos} = |E| - \text{posto}(A) \quad (4)$$

Demonstração:

$$\begin{aligned} \text{posto}(A) + \dim(N(A)) &= |E| \\ \Leftrightarrow |E| - \text{posto}(A) &= \dim(N(A)) \end{aligned} \quad (5)$$

Porém, a dimensão do núcleo de A é a quantidade de ciclos no grafo, então eu tenho que:

$$\text{n}^\circ \text{ de ciclos} = |E| - \text{posto}(A) \quad (6)$$

□

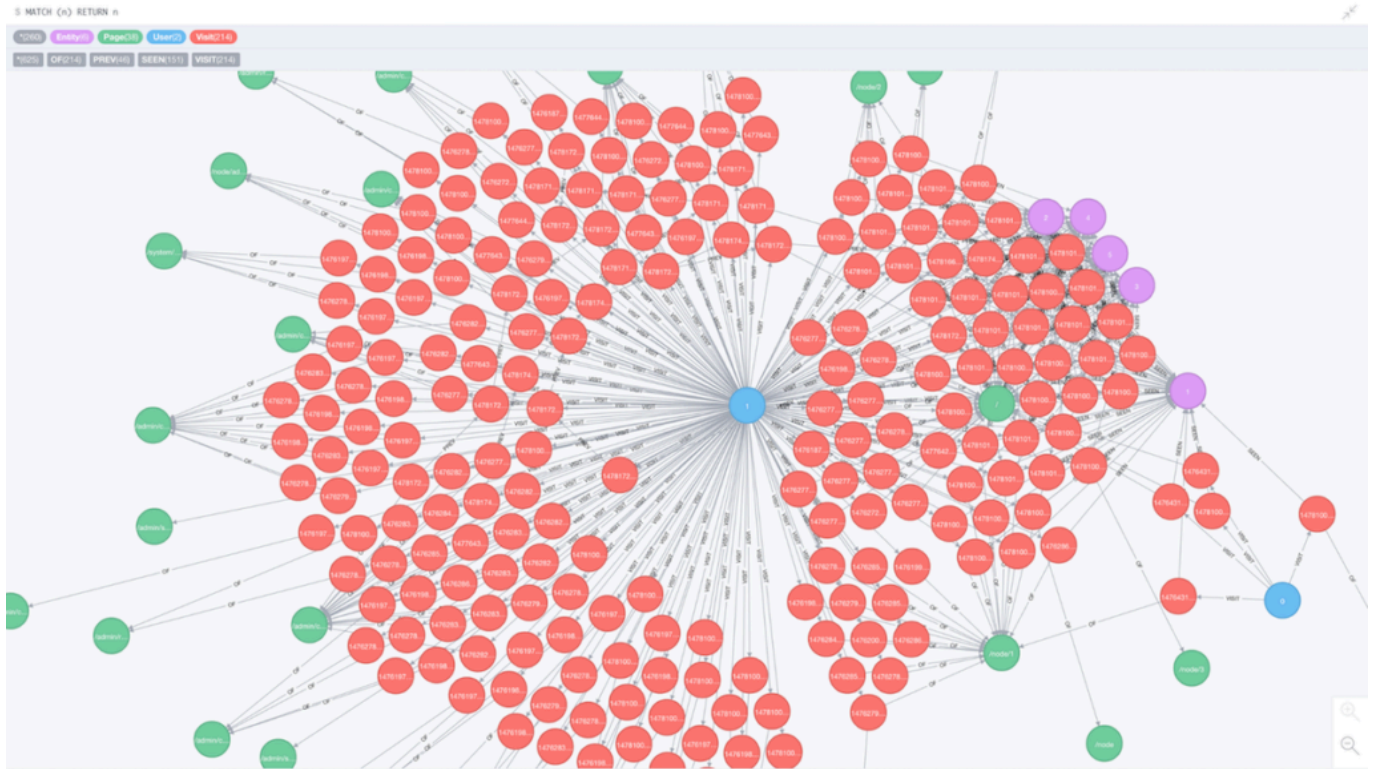
Definição 1.3 (Coeficiente de Clustering): Dado um grafo $G(V, E)$, o coeficiente de clustering de um nó $v \in V$ é:

$$C(v) := \frac{2E_v}{\delta(v)(\delta(v) - 1)} \quad (7)$$

onde E_v é a quantidade de arestas ligadas aos nós vizinhos

Medidas de Centralidade

Quando estamos vendo aplicações reais de grafos, é muito comum querermos ver o “quão importante” um nó é no contexto que estamos analisando. Por exemplo, se nosso grafo representa as conexões entre servidores que um pacote pode percorrer, faz muito sentido querermos ver qual o servidor que quase todos os pacotes percorrem



Imagine que esse é o grafo que estávamos falando (Não importa o que ele representa de verdade, só finge que é o caso que falamos), então o nó azul tem uma importância MUITO grande, mas como podemos medir isso? Nem sempre o grafo vai tá arrumadinho assim pra gente. Daí que surgem as medidas de Centralidade.

Definição 2.1 (Farness/'Lonjura'): Dado um grafo $G(V, E)$, a farness de um vértice v_i é dada por

$$L(v_i) := \sum_{v_i \neq v_j \in V} d(v_i, v_j) \quad (8)$$

onde $d(v_i, v_j)$ é o tamanho do menor caminho entre v_i e v_j

Essa medida mede o quão longe o nó está dos outros, de forma que, quanto maior essa medida é, menos importante o meu nó é (Depende do contexto analisado)

Definição 2.2 (Closeness/Proximidade): Dado um grafo $G(V, E)$, a proximidade/closeness do vértice $v_i \in V$ é dada por:

$$C(v_i) := \frac{|V|}{L(v_i)} \quad (9)$$

Por convenção, se v_i e v_j estão em componentes conexas separadas em G , então $d(v_i, v_j) = \infty$, o que torna a definição de antes inútil, então podemos redefinir como:

$$C(v_i) := \frac{1}{|V|} \sum_{v_i \neq v_j \in V} \frac{1}{d(v_i, v_j)} \quad (10)$$

Definição 2.3 (Betweenness/Intermediação): Dado um grafo $G(V, E)$ e $P(v_i, v_j)$ o conjunto de todos os menores caminhos possíveis entre v_i e v_j , então a intermediação de v_i é:

$$B(v_i) := \sum_{v_s, v_t \in V} \frac{|c \in P(v_s, v_t); v_i \in c|}{|P(v_s, v_t)|} \quad (11)$$

Saindo um pouco dessas definições, vamos tentar pensar em alguma medida mais básica e intuitiva. Uma medida bem padrão que podemos pensar logo de cara é simplesmente o grau do vértice, já que, quanto mais vértices ele se ligar, mais importante ele é! Em muitas literaturas sobre redes o grau do vértice é chamado de **Centralidade de Grau**.

Um outro pensamento que pode surgir a partir desse é: “Poxa, meu vértice tem um grau alto, então ele é importante, mas eu quero valorizar aqueles vértices que se conectam com ele, afinal, se ele é importante, os vértices que estão diretamente ligados nele também são, não é?”, e esse pensamento não está errado! É dessa ideia que surge a centralidade por autovetor. Funciona assim: Vamos inicialmente assumir que todos os nossos vértices v_i tem importância $x_i^{(0)} = 1$, o que não me é muito útil agora, porém, vamos tentar fazer uma nova estimativa baseada nos vizinhos, que tal a nova centralidade do vértice v_i ser a soma da centralidade dos vizinhos? Isso faz com que a importância do v_i se baseie no quão importante são seus vizinhos! Eu posso expressar isso com uma fórmula:

$$x_i^{(1)} = \sum_j A_{ij} x_j^{(0)} \quad (12)$$

Onde A é minha matriz de adjacência. Se meu nó v_i não é vizinho de v_j , então $A_{ij} = 0$ o que faz com que minha centralidade $x_j^{(0)}$ não seja somada. Posso reformular isso de forma matricial:

$$x^{(1)} = Ax^{(0)} \quad (13)$$

onde $x^{(k)}$ é o vetor com entradas $x_i^{(k)}$. Se fizermos esse processo várias vezes, depois de k passos, vamos ter algo do tipo:

$$x^{(k)} = A^k x^{(0)} \quad (14)$$

Tomemos a liberdade, então, de escrever $x^{(0)}$ como uma combinação linear dos autovetores w_j de A de forma que

$$x^{(0)} = \sum_{j=1}^n c_j w_j \quad (15)$$

Para alguma escolha apropriada de c_j . Então temos:

$$x^{(k)} = A^k \sum_{j=1}^n c_j w_j = \sum_{j=1}^n c_j \lambda_j^k w_j = \lambda_1^k \sum_{j=1}^n c_j \left(\frac{\lambda_j}{\lambda_1} \right)^k w_j \quad (16)$$

De forma que λ_j são os autovalores de A e λ_1 pode ser, sem perda de generalização, o maior de todos em módulo. Como $\lambda_i/\lambda_1 < 1 \forall \lambda_i$ com $i \neq j$, então:

$$\lim_{k \rightarrow \infty} \sum_{j=1}^n c_j \lambda_j^k w_j = c_1 \lambda_1 w_1 \quad (17)$$

Ou seja, o vetor de centralidades que limita as centralidades que eu fiz antes é proporcional ao autovetor associado ao maior autovalor de A , que é equivalente a dizer que o vetor de centralidades x satisfaz:

$$Ax = \lambda_1 x \quad (18)$$

Definição 2.4 (Centralidade Autovalor): Seja r um vetor com as centralidades dos vértices v_i de uma rede G de forma que r_i = centralidade de v_i , então:

$$Ar = \lambda_1 r \quad (19)$$

onde λ_1 é o maior autovalor de A

Agora temos outro problema. Quando temos um grafo dirigido, essa medida de centralidade autovalor já não funciona, já que se um nó não tem nenhuma aresta apontando para ele (Apenas saem arestas dele), ele não terá sequer uma centralidade, e isso afeta não só esse vértice como os vértices que ele aponta, que não terão nenhuma “pontuação” adicionada por serem apontados por esse vértice, e isso não pode ocorrer, já que não faz muito sentido na maioria das aplicações práticas. O que podemos fazer para contornar isso? Então entra a solução a seguir:

$$x_i = \alpha \sum_j A_{ij} x_j + \beta \quad (20)$$

Onde α e β são constantes positivas. O primeiro termo é a centralidade autovetor que vimos antes, porém o termo β garante que os nós que comentei anteriormente (Sem grau de entrada) possuam uma pontuação e possam contribuir para a pontuação dos nós que eles apontam. Essa medida é interessante por conta do termo α que balanceia o termo constante e a medida de centralidade autovetor. Podemos expressar isso de forma matricial:

$$x = \alpha Ax + \beta \mathbf{1} \quad (21)$$

Onde $\mathbf{1} = (1, \dots, 1)$. Se rearranjarmos para x , obtemos:

$$x = \beta(I - \alpha A)^{-1} \mathbf{1} \quad (22)$$

Normalmente colocamos $\beta = 1$ pois não estamos interessados em saber o valor exato das centralidades, mas saber quais vértices são ou não mais ou menos centrais.

$$x = -\alpha \left(A - \frac{1}{\alpha} I \right)^{-1} \quad (23)$$

Perceba que eu quero que $A - \frac{1}{\alpha} I$ seja invertível, e isso acontece quando $\frac{1}{\alpha} \neq \lambda_j$ onde λ_j são os autovalores de A . Ou seja, o meu α não é completamente arbitrário, eu vou ter que analisar

o contexto da minha aplicação. Porém, muito comumente, se é utilizado $\alpha = \frac{1}{\lambda_1}$ com λ_1 sendo o maior autovalor

Definição 2.5 (Centralidade de Katz): Dado uma rede $G(V, E)$ e duas constantes $\alpha, \beta > 0$, o vetor de centralidades de katz de todos os nós em V é:

$$K(V) = \beta(I - \alpha A)^{-1} \mathbf{1} \quad (24)$$

Onde A é a matriz de adjacência de G . ($K(V) \in \mathbb{R}^{|V|}$)

Um outro tipo de medida surge quando queremos responder a questão: “Se eu estou navegando entre meus nós, ao longo prazo, qual é o nó que eu mais vou percorrer/parar nele?”. Um exemplo são páginas na internet que referenciam entre si, daí surge o nome da medida: **PageRank**. O que fazemos essencialmente é transformar a rede em uma cadeia de markov. Por exemplo:




Figura 1: Grafo de Exemplo 1

Vamos supor que estamos no nó 4 e queremos escolher aleatoriamente entre os nós 3 e 1 para irmos, como podemos ver na distribuição dos pesos (Nesse exemplo, isso indica que a página 4 tem 2 links referenciando a página 1 e apenas 1 link referenciando a página 3), então teríamos:

$$\begin{aligned} \mathbb{P}(4 \rightarrow 3) &= \frac{1}{3} \\ \mathbb{P}(4 \rightarrow 1) &= \frac{2}{3} \end{aligned} \quad (25)$$

E fazemos isso definindo uma matriz estocástica H de tal forma que:

$$H_{ij} = \frac{A_{ij}}{\sum_k^n A_{ik}} \quad (26)$$

Com A sendo a matriz de adjacência. De forma que a soma de todos os elementos de uma coluna dê 1. Agora que vem o truque interessante. Dado um vetor $p \in \mathbb{R}^n$ de forma que cada entrada de p_i representa a chance de eu ir do nó que eu estou para o nó v_i (Ou seja, p tem que ser alguma coluna de H), ao fazer a operação:

$$Hp \quad (27)$$

Eu estou ponderando as probabilidades de p com os seus respectivos nós, ou seja, $(Hp)_k$ representa a probabilidade esperada de que, ao sair do nó v_i , eu vá para o nó v_k . Se isso é verdade e, como eu defini antes, eu quero saber qual nó é mais visitado conforme se passa o tempo, faz sentido eu refazer esse processo inúmeras vezes, então eu tenho uma centralidade do vértice v_i :

$$r = \lim_{t \rightarrow \infty} H^t p \quad (28)$$

Com p sendo a i -ésima coluna de H . Porém isso ainda nos trás um problema, veja essa outra rede:




Figura 2: Grafo de Exemplo 2

Veja que, por conta do nó 6, eu não posso transformar meu esquema em uma cadeia de markov, pois eu teria uma coluna de 0, e no caso dos nós 7 e 8 eu teria um problema por conta que eles sempre vão um para o outro. Como podemos resolver isso? O PageRank vem para resolver isso. Vamos pensar no caso da internet, você navegador aleatório, uma hora, pode se cansar de estar onde estar, e visitar uma página aleatoriamente dentro da sua rede, e é nessa ideia que trabalhamos em cima.

Definimos um $\alpha \in (0, 1)$, onde podemos interpretar α como a chance do meu navegador permanecer no meu nó. Definimos então nossa nova matriz de chances da seguinte forma:

$$\mathbb{G} = \alpha H + (1 - \alpha)C \quad (29)$$

De forma que C é uma matriz $n \times n$ com todas as entradas iguais a $1/n$ para representar um dirigido onde todos os nós apontam para todos os outros nós (Representando a ideia de que eu posso ir para o nó que eu quiser). Porém, há uma propriedade que, se eu tenho uma combinação convexa entre duas matrizes estocásticas/markovianas, então o resultado é uma matriz markoviana. Ou seja, eu ainda posso aplicar a mesma ideia de antes do vetor p_0 inicial e aplicar o limite, assim, eu vou obter meu vetor de centralidades r , de tal forma que

$$\lim_{t \rightarrow \infty} \mathbb{G}^t p_0 = r \quad (30)$$

Definição 2.6 (PageRank): Sejam a matriz \mathbb{G} como definida anteriormente e o vetor inicial p_i sendo a i -ésima coluna de \mathbb{G} , então o vetor de centralidades PageRank r onde a k -ésima entrada é a centralidade de v_k , então:

$$r = \lim_{t \rightarrow \infty} \mathbb{G}^t p_0 \quad (31)$$

Redes Aleatórias

3.1 Ideia Inicial

Também chamadas de **Redes Erdős-Renyi** ou **Redes de Poisson**, são tipos de redes que vão se montando aleatoriamente. Por exemplo, imagine que você está em uma festa e o anfitrião está fornecendo um vinho da melhor qualidade, mas ele não avisou ninguém. Um convidado curioso, por acidente, provou desse vinho e **adorou**, então ele vai contar para as pessoas da festa. A pergunta é, para quem ele vai falar? Ele vai falar para todos? Vai sobrar vinho para você?

Em cima disso conseguimos montar as redes aleatórias, onde cada par de nós (Aresta) é formado de acordo com uma **probabilidade**

Definição 3.1.1 (Rede Aleatória): Uma rede aleatória é um grafo $G(V, E)$ de $|V| = N$ nós onde cada par de nós é conectado por uma probabilidade p

Considere, agora, uma rede aleatória $G(V, E)$ com $|V| = N$. Sendo L a variável aleatória que representa a quantidade de arestas em E , queremos descobrir sua distribuição. Como cada aresta tem uma probabilidade p de aparecer, podemos interpretar como ela aparecer ou não sendo uma variável indicadora, de forma que o número total de arestas segue uma distribuição binomial (Soma de variáveis de bernoulli independentes). Ou seja, a probabilidade a quantidade de arestas ser $L = l$ é:

$$\mathbb{P}(L = l) = \binom{N}{2} p^l (1-p)^{\frac{N(N-1)}{2} - l} \quad (32)$$

Podemos aplicar a mesma ideia para o grau de um vértice também. Vamos definir que K é a variável aleatória que representa o **grau de um vértice arbitrário**, então:

$$\mathbb{P}(K = k) = \binom{N-1}{k} p^k (1-p)^{N-1-k} \quad (33)$$

Já que meu vértice pode se ligar a $N - 1$ vértices com probabilidade p , então isso vira a soma das variáveis indicadores que são 1 quando o meu vértice se liga com outro vértice ($\mathbb{P}(\mathbb{I} = 1) = p$), de forma que eu tenho a soma de $N - 1$ variáveis de bernoulli independentes

Com isso, nós podemos definir o grau médio de G como $\mathbb{E}[K]$:

$$\delta_{\text{med}}(G) = \mathbb{E}[K] = (N - 1)p \quad (34)$$

E podemos obter também a variância dos graus

$$\mathbb{V}(K) = (N - 1)p(1 - p) \quad (35)$$

Então, apenas para resumir, temos que:

$$\begin{aligned} L &\sim \text{Bin}\left(\binom{N}{2}, p\right) \\ K &\sim \text{Bin}(N - 1, p) \end{aligned} \quad (36)$$

Porém, em redes reais, elas são **esparsas**, ou seja, eu tenho **muitos** nós e graus pequenos ($N \gg \mathbb{E}[K]$ notação que diz que N é **muito maior** que $\mathbb{E}[K]$). E lembra qual é a distribuição que é a binomial com n muito grande? Exato, a **Poisson**! Essas redes aleatórias também são chamadas de **redes de poisson**. Vamos, a partir de agora, denotar $\delta_{\text{med}}(G) = \mathbb{E}[K] = \hat{k}$

$$\mathbb{P}(\delta(v) = k) = e^{-\hat{k}} \frac{\hat{k}^k}{k!} \quad (37)$$

Ou seja, para N muito grande e k pequeno com relação a N , podemos estimar de forma que:

$$K \sim \text{Poisson}(\hat{k}) \quad (38)$$

E isso tudo nos dá um resultado bem condizente e intuitivo, que é que, conforme nós aumentamos a probabilidade p de uma aresta existir, então a rede vai ficando cada vez mais densa

3.2 Evolução das Redes Aleatórias

Conforme iniciamos um grafo com um grau médio 0 e vamos aumentando ele aos poucos, nós percebemos que a partir de um ponto chave, os nós começam a se agrupar em algo que chamamos de **componente gigante**, que seria a maior componente conexa da rede.




Figura 3: Gráfico que mostra a fração de nós dentro de uma grande componente conexa em função do grau médio

Quanto $\hat{k} < 1$, então a quantidade de nós na componente gigante é desprezível em relação à quantidade de nós na rede, porém, a partir de $\hat{k} = 1$, isso indica que temos, pelo menos, $\frac{n}{2}$ componentes conexas, o que já começa a fazer uma diferença no gráfico. Esse é um argumento utilizado por Erdős e Renyi em um paper por eles publicado

Teorema 3.2.1 (Ponto Crítico): Temos uma componente gigante $\Leftrightarrow \mathbb{E}[K] \geq 1$

Demonstração: Dado uma rede $G(V, E)$, vamos definir a fração de nós que **não está** na componente gigante como:

$$u = 1 - \frac{N_G}{|V|} \quad (39)$$

De forma que N_G é a quantidade de nós dentro dessa componente gigante, vamos definir essa componente como $\Psi \subseteq V$. Se um nó $v_i \in \Psi$, então ele deve estar interligado com outro

nó v_j , que também deve satisfazer $v_j \in \Psi$. Por isso, se $v_i \notin \Psi$, então isso pode ocorrer por duas razões:

- $\{v_i, v_j\} \notin E$. A probabilidade de isso acontecer é $1 - p$
- $\{v_i, v_j\} \in E$, porém $v_j \notin \Psi$. A probabilidade de isso acontecer é pu

Então temos:

$$\mathbb{P}(v_i \notin \Psi) = 1 - p + pu \quad (40)$$

Então a probabilidade de que v_i não esteja linkado a Ψ por qualquer nó é de $(1 - p + pu)^{|V| - 1}$, já que temos outros $|V| - 1$ nós que poderiam fazer com que v_i se interligasse a componente gigante.

Sabemos que u é a fração de nós que não está em Ψ , para qualquer p e $|V|$, a solução da equação

$$u = (1 - p + pu)^{|V| - 1} \quad (41)$$

nos dá o tamanho da componente gigante por meio de $N_G = |V|(1 - u)$. Usando $p = \frac{\hat{k}}{|V| - 1}$ e tirando log de ambos os lados, para $\hat{k} \ll |V|$ (Grau médio **muito** menor que $|V|$), obtemos:

$$\ln(u) \approx (|V| - 1) \ln \left[1 - \frac{\hat{k}}{|V| - 1} (1 - u) \right]$$

Tiramos exponencial e obtemos: (42)

$$u \approx \exp \left\{ -\frac{\hat{k}}{1 - u} \right\}$$

Se denotarmos $S = \frac{N_G}{|V|}$, obtemos que:

$$S = 1 - e^{-\hat{k} \cdot S} \quad (43)$$

Agora obtemos o tamanho da componente gigante em função do **grau médio**. O ponto crítico ocorre na mudança de fase do sistema (Tópico mais complicado que não compreendo, estou apenas falando o que o livro do Barabás fala), que é quando os dois lados da igualdade tem a mesma derivada, então:

$$\frac{d}{dS} (1 - e^{\hat{k}S}) = 1$$

$$\hat{k}e^{-\hat{k}S} = 1 \quad (44)$$

Onde, colocando $S = 0$, descobrimos que o ponto crítico é $\hat{k} = 1$ □

Na verdade esse resultado é bem intuitivo. Faz sentido dizer que para que uma componente gigante exista, todos os nós precisam ter pelo menos grau 1, já que eles precisam estar conectados com algum outro nó, porém, o que não é muito intuitivo, é que todos eles terem grau 1 é **suficiente** para que a componente gigante apareça

A gente pode reescrever $\mathbb{E}[K] = 1$ como:

$$\mathbb{E}[K] = 1 \Leftrightarrow p(N - 1) = 1 \Leftrightarrow p = \frac{1}{N - 1} \approx \frac{1}{N} \quad (45)$$

E o que isso significa? Isso mostra outro resultado intuitivo. Quanto maior é minha rede, **menos probabilidade eu preciso para que uma componente gigante apareça**

Algo interessante que podemos fazer é analisar como a proporção $\frac{N_G}{N}$ (Porcentagem de nós dentro da componente gigante) se comporta conforme nós aumentamos $\mathbb{E}[K]$. Nós fazemos isso dividindo esse processo em 4 fases (Ou 4 **regimes**), veja a imagem abaixo:

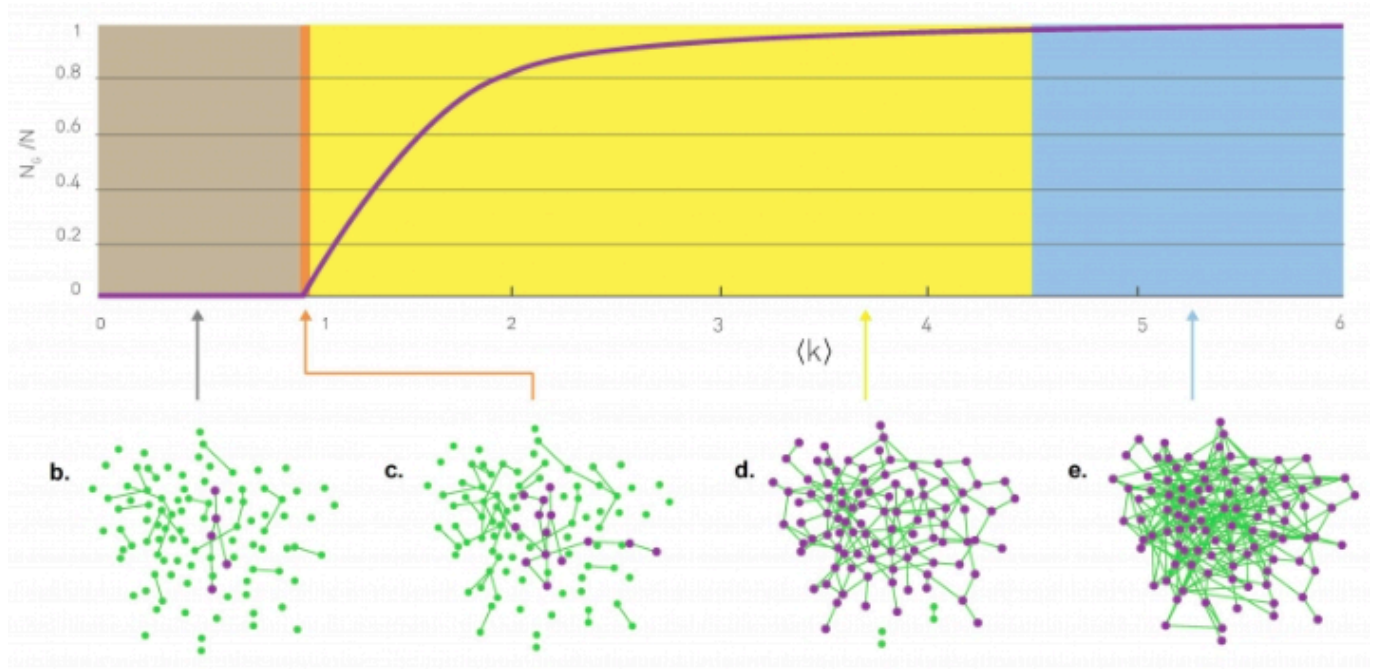


Figura 4: Crescimento da componente conexa em função do grau médio

3.2.1 Regime Subcrítico ($0 < \hat{k} < 1$)

Quando $\hat{k} = 0$, temos N nós soltos na rede e conforme aumentamos \hat{k} , mas mantemos ele menor que 1, temos a formação de vários nós soltos e pequenos agrupamentos (Coisa pouca mesmo). Dessa forma, mesmo escolhendo a componente gigante como o maior desses agrupamentos, a proporção N_G/N ainda vai ser muito baixa. O Barabás aproxima essa relação como

$$\frac{N_G}{N} \approx \frac{\ln(N)}{N} \rightarrow 0 \text{ quando } N \rightarrow \infty \quad (46)$$

Pois podemos considerar essas componentes menores como várias árvores (Também pequenas)

3.2.2 Ponto Crítico

É a transição do momento onde não há uma componente gigante para o momento que há uma. Porém o tamanho relativo dela (N_G/N) ainda é muito próximo de 0. O livro do Barabás afirma que $N_G \approx N^{\frac{2}{3}}$, então N_G cresce muito mais devagar se comparado a N , logo:

$$\frac{N_G}{N} \approx N^{-\frac{1}{3}} = O(N) \quad (47)$$

Porém, perceba que o salto de diferença de tamanho pode ser enorme dependendo da rede. Se pegarmos uma rede de tamanho $N = 7 \times 10^9$ (Parecido com a rede mundial), para $\hat{k} < 1$, a gente teria que o tamanho da componente gigante era de ordem:

$$N_G \approx \ln(N) \approx 22.7 \quad (48)$$

Em contraste, se $\hat{k} = 1$, então teríamos que

$$N_G \approx N^{\frac{2}{3}} \approx 3 \times 10^6 \quad (49)$$

Que é uma diferença notável no tamanho das componentes gigantes

3.2.3 Regime Supercrítico ($\hat{k} > 1$)

Esse regime tem mais relevância para redes reais, já que a componente gigante começa a se parecer realmente com uma rede. Aqui, o tamanho N_G pode ser dado como:

$$N_G = (p - p_c)N \quad (50)$$

Onde $p_c = 1/(N)$. Ou seja, conforme eu aumentar meu grau médio, menor vai ficar meu p e maior será a fração de nós que pertencem à componente gigante. Em resumo, nesse regime, várias componentes conexas coexistem junto da componente gigante, onde a componente gigante é uma rede comum, enquanto as outras componentes conexas são mais prováveis de serem árvores

3.2.4 Regime Conexo ($\hat{k} > \ln(N)$)

Agora, nesse regime, temos que o grafo é (ou quase) conexo, logo, todos os nós fazem parte da componente conexa (Ou a maioria, logo $N_G \approx N$)

Teorema 3.2.4.1: Se $N_G \approx N$, o valor de \hat{k} que satisfaz a propriedade de **a maior parte dos nós estarem na componente gigante** é:

$$\hat{k} = \ln(N) \Rightarrow p = \frac{\ln(N)}{N} \quad (51)$$

Demonstração: Para determinar o valor de \hat{k} no qual a maior parte dos nós fazem parte da componente gigante, temos que saber a probabilidade de que um **nó aleatório não tenha um link para a componente gigante**, e isso é:

$$(1 - p)^{N_G} \approx (1 - p)^N \quad (52)$$

Já que eu tenho exatamente N_G nós na componente gigante e eu não quer me ligar com nenhum deles. Novamente, tomando \mathbb{I}_k sendo a variável indicadora de que um nó k **não** na componente gigante (1 quando ele não está), temos que a **quantidade de nós que não estão na componente gigante** tem uma distribuição **binomial** com parâmetros $N, (1 - p)^N$, então, se considerarmos L_G sendo essa quantidade, temos que:

$$\mathbb{E}[L_G] = N(1 - p)^N = N \left(1 - \frac{Np}{N}\right)^N \approx Ne^{-Np} \quad (53)$$

Queremos então chegar no ponto em que temos, para um p suficientemente próximo de 1, que apenas 1 único nó esteja fora da componente conexa, então gostaríamos de analisar em que ponto:

$$\mathbb{E}[L_G] = 1 \Leftrightarrow Ne^{-Np} = 1 \quad (54)$$

Logo, tirando \ln em ambos os lados, chegamos que:

$$p = \frac{\ln(N)}{N} \quad (55)$$

Ou seja

$$\hat{k} = \ln(N) \quad (56)$$

□

Esse resultado é de grande impacto! Quando analisamos muitas das redes reais, a maioria segue esse padrão de $\hat{k} = \ln(N)$, logo, as **redes reais são supercríticas**

3.3 Distribuição de tamanhos de Cluster

Queremos também ter uma noção da probabilidade de um nó v_i qualquer estar em um cluster (Grupo de nós na rede) de tamanho s . No livro do Newman, ele nos mostra que essa probabilidade é:

$$\mathbb{P}(v_i \in \Psi_{|\Psi|=s}) = e^{-\delta_{\text{med}}(G) \cdot s} \frac{(\delta_{\text{med}}(G) \cdot s)^{s-1}}{s!} \quad (57)$$

3.4 Mundos pequenos

Mundos pequenos (Small worlds) são grafos em que, independente da quantidade de vértices, a distância entre dois nós aleatórios costuma ser muito pequeno. Um exemplo é um modelo que cada nó representa todas as pessoas do mundo e as arestas indicam se elas já interagiram e se conhecem ou não (Impressionantemente), tanto que existe a teoria dos 6 graus de distância entre as pessoas

Vídeo sobre o assunto (Clique aqui)

E se quisermos ter uma noção de o quão **não-relacionadas** duas pessoas são em uma rede social? Podemos calcular sua distância, obviamente, mas alguns algoritmos ficam computacionalmente inviáveis. Podemos então estimar uma distância média entre dois nós selecionados aleatoriamente no grafo




Figura 5: Grafo Árvore

Redes aleatórias costumam ter uma topologia de árvore com praticamente um número constante de graus. Perceba então que eu posso escrever a quantidade de nós $|V|$ como:

$$\begin{aligned} |V| &= 1 + \delta_{\text{med}}(G) + \dots + \delta_{\text{med}}(G)^{d_{\text{max}}} \\ &= \frac{\delta_{\text{med}}(G)^{d_{\text{max}}} - 1}{\delta_{\text{med}}(G) - 1} \end{aligned} \quad (58)$$

Então vamos ter que:

$$d_{\text{max}} \approx \frac{\log|V|}{\log(\delta_{\text{med}}(G))} \quad (59)$$

3.5 Coeficiente de Clustering

Indica o quão agrupado um nó está dentro de uma rede

Definição 3.5.1 (Coeficiente de Clustering): Dado uma rede $G(V, E)$, o coeficiente de clustering de um nó $v_i \in V$ é definido como:

$$\text{Cluster}(v_i) := \frac{2 \cdot \mathbb{L}(v_i)}{\delta(v_i)(\delta(v_i) - 1)} \quad (60)$$

Onde $\mathbb{L}(v_i)$ é quantas arestas **entre si** os **vizinhos** de v_i possuem e $\frac{\delta(v_i)(\delta(v_i)-1)}{2}$ é a quantidade **máxima** de arestas que poderiam estar interligando os vizinhos de v_i (Quantidade de arestas em um grafo completo $K_{\delta(v_i)}$)

Em redes aleatórias, como as arestas são independentes e tem a mesma probabilidade p de aparecer, temos:

$$\mathbb{L}(v_i) \approx p \frac{\delta(v_i)(\delta(v_i) - 1)}{2} \Rightarrow \text{Cluster}(v_i) = p = \frac{\delta_{\text{med}}(G)}{|V|} \quad (61)$$

Só que sabemos que, em redes aleatórias, para que esse número seja alto, a probabilidade em si das arestas tem que ser alto, porém, se p é alto, então a rede aleatória em si será um grande aglomerado, seria um único cluster enorme. Essa característica é um forte indicativo, por exemplo, de que redes como as **redes sociais não são** redes aleatórias

3.6 Conclusão

Como conclusão, temos que redes aleatórias **não representam bem as redes da vida real**. Não existem redes na natureza que são corretamente descritas como **redes aleatórias**. Então por que estudar elas? Na verdade, veremos posteriormente que, mesmo elas sendo erradas e irrelevantes, elas são **muito úteis**

Evoluções de Redes

Vimos as redes aleatórias onde os graus dos nós tinham distribuição de Poisson. Mas e se eu quisesse fazer uma rede com distribuição diferente? Muitos pacotes de grafos e redes utilizam de **configuration models**, que são funções que recebem a quantidade de nós da rede e um **vetor** que representa a **função de distribuição** dos graus dos nós

Voltando ao assunto sobre **evoluções**, eu estou interessado em pensar um jeito intuitivo/natural de como as redes vão evoluir com o passar do tempo.

Então vamos imaginar o seguinte cenário. Eu tenho uma rede inicial $G_0(V_0, E_0)$ e a cada unidade de tempo t eu vou ter uma nova rede $G_t(V_t, E_t)$, de forma que a cada unidade de tempo, eu vou adicionar um novo nó em V_{t-1} e novas arestas em E_{t-1} . Qual é a distribuição do grau médio desses nós? O que podemos inferir dessa rede?

4.1 Anexação Uniforme

Vamos imaginar uma **anexação uniforme**. Nesse caso, cada nó inserido sempre terá um grau de m . Ou seja, a **probabilidade** de um link do meu novo nó inserido se interligar ao vértice v_i é igual a m/i (A chance de ele se ligar com uma das arestas é $1/i$, logo, como eu posso me ligar com m arestas diferentes, todas independentes entre si, a probabilidade total vai ser m/i), logo:

$$\delta(v_j, t = i) := \text{Grau de } v_j \text{ no momento } i \quad (62)$$

Com isso, podemos interpretar esse grau como uma **variável aleatória**. Temos que o grau de v_i no momento inicial i é fixa como m . Então a quantidade de arestas no momento $i + 1$ pode ser escrita como:

$$\delta(v_i, i + 1) = m + \mathbb{I}_{i+1}(1) + \mathbb{I}_{i+1}(2) + \dots + \mathbb{I}_{i+1}(m) \quad (63)$$

Onde $\mathbb{I}_j(k)$ é a variável indicadora que diz se, no momento j , a aresta k do **novo nó que está sendo adicionado na rede** foi adicionado ou não no nosso nó. Podemos reescrever como a soma de uma única variável aleatória de distribuição binomial também. Você pode ter reparado que eu utilizei i tanto no v_i quanto no i . Vou utilizar isso pois eu estou supondo que, na nossa análise, estamos saindo do último nó adicionado (Uma aproximação razoável do modelo real, obviamente que nem todos os nós vão ser adicionados com essa anexação, já que antes de eu iniciar essa abordagem, já vai ter uma rede “preexistente”)

Porém, queremos ter uma **noção** de como isso vai ser ao longo prazo, podemos então tirar a esperança disso.

$$\mathbb{E}[\delta(v_i, i + 1)] = m + \frac{m}{i} \quad (64)$$

Porém, isso é apenas para um único passo, queremos generalizar para vários passos. Vamos supor então que estamos saindo do i -ésimo nó adicionado e estamos no momento t :

$$\delta(v_i, t) = m + \sum_{k=i+1}^t \sum_{j=1}^m \mathbb{I}_k(j) \quad (65)$$

$$\begin{aligned} \mathbb{E}[\delta(v_i, t)] &= m + \sum_{k=i+1}^t \sum_{j=1}^m \mathbb{E}[\mathbb{I}_k(j)] \\ &= m + \sum_{k=i+1}^t \sum_{j=1}^m \frac{j}{k-1} \end{aligned} \quad (66)$$

$$\begin{aligned}
\mathbb{E}[\delta(v_i, t)] &= m \cdot \sum_{k=i+1}^t \frac{1}{k-1} \\
\mathbb{E}[\delta(v_i, t)] &\approx m + m \ln\left(\frac{t-1}{i-1}\right) \\
\frac{\mathbb{E}[\delta(v_i, t)]}{m} - 1 &\approx \ln\left(\frac{t-1}{i-1}\right) \\
\exp\left(\frac{\mathbb{E}[\delta(v_i, t)] - m}{m}\right) &\approx \frac{t-1}{i-1} \\
\exp\left(-\frac{\mathbb{E}[\delta(v_i, t)] - m}{m}\right) &\approx \frac{i-1}{t-1} \\
\exp\left(-\frac{\mathbb{E}[\delta(v_i, t)] - m}{m}\right) &\approx \frac{i}{t}
\end{aligned} \tag{67}$$

No intervalo $[0, t]$, temos a seguinte estruturação:




Figura 6: Intervalo de i/t

Então, o que encontramos foi a fração de nós que tem grau maior que v_i . Então temos que:

$$\mathbb{P}(\delta_t(v_i) \leq k) = 1 - e^{-\frac{k-m}{m}} \tag{68}$$

Logo, temos uma distribuição **Exponencial**

4.2 Anexação Preferencial

Na anexação **uniforme**, cada novo nó podia se ligar com um dos nós anteriores com mesma probabilidade. Nessa abordagem, os nós de **maior grau** terão uma **maior preferência** para serem escolhidos (Não é uma obrigatoriedade). Podemos expressar, então da seguinte forma. Antes, vamos fazer duas definições rápidas:

Definição 4.2.1: Dada uma rede $G(V, E)$, o conjunto E_t é definido como o conjunto de arestas da rede no momento t

Definição 4.2.2: Dado uma rede $G(V, E)$, a função $\delta_t : V \rightarrow \mathbb{N}$ é a função que retorna o grau de um vértice em um momento t do tempo

Voltando, queremos então, antes de tudo, saber qual que é a probabilidade do nó que vai ser adicionado se ligar com um vértice v_i , então:

$$\mathbb{P}(\{v_i, v_{t+1}\} \in E_{t+1}) = \frac{\delta_t(v_i)}{\sum_{j=1}^t \delta_t(v_j)} \tag{69}$$

Queremos achar uma distribuição para os graus dos nós. Vamos tentar achar, então, uma taxa de crescimento do grau dos nós:

$$\frac{\delta_{t+1}(v_i) - \delta_t(v_i)}{\Delta t} = m \cdot \frac{\delta_t(v_i)}{\sum_{j=1}^t \delta_t(v_j)} \approx \frac{d(\delta_t(v_i))}{dt} \quad (70)$$

Porém, sabemos que $\sum_{j=1}^t \delta_t(v_j) = 2 |E_t|$, então vamos obter:

$$\frac{d(\delta_t(v_i))}{dt} = m \cdot \frac{\delta_t(v_i)}{2 |E_t|} = m \cdot \frac{\delta_t(v_i)}{2tm} = \frac{\delta_t(v_i)}{2t} \quad (71)$$

Logo, obtemos uma EDO para resolver. Vamos chamar $\delta_t(v_i)$ de k apenas para facilitar a visualização:

$$\begin{aligned} \frac{dk}{dt} &= \frac{k}{2t} \quad (\delta_t(v_i) = m) \\ \frac{dk}{k} &= \frac{dt}{2t} \\ \int \frac{dk}{k} &= \int \frac{dt}{2t} \\ \ln k &= \frac{1}{2} \ln t + C \\ \delta_t(v_i) &= t^{1/2} \cdot D \end{aligned} \quad (72)$$

Resolvendo para o caso $\delta_t(i) = m$, temos:

$$\begin{aligned} m &= i^{1/2} D \Rightarrow D = m \cdot i^{-1/2} \\ \Rightarrow \delta_t(v_i) &= m \left(\frac{t}{i} \right)^{1/2} \end{aligned} \quad (73)$$

Queremos então calcular $\mathbb{P}(\delta_t(v_i) \leq k)$. Na média, todos os nós **posteriores** ao nó v_i tem grau menor do que k , então precisamos apenas inverter aquela equação de antes, assim, vamos obter:

$$\begin{aligned} \delta_t(v_i)^2 &= m^2 \frac{t}{i} \\ \Leftrightarrow i &= \frac{m^2 \cdot t}{\delta_t(v_i)^2} \end{aligned} \quad (74)$$

Assim, conseguimos obter a **fração de nós com grau maior que v_i** , que são justamente os nós anteriores a ele (i/t) que é $m^2 \delta_t(v_1)^{-2}$. Temos então que:

$$\mathbb{P}(\delta_t(v_i) \leq k) = 1 - m^2 k^{-2} \quad (75)$$

Temos também que a densidade vai ser:

$$f_K(k) = 2m^2 k^{-3} \quad (76)$$

Percebemos, então, que a variável aleatória K , que representa o grau de um nó na rede, tem a distribuição **Pareto(2, m)**